数据来源与使用合规声明

《商业数据分析》期末大作业

项目	内容
数据集	NYC TLC Yellow Taxi Trip Records 2024
学院 / 专业	数据科学学院 / 数据科学与大数据技术
作者 / 学号	_____孔梦____ / _____2024459985106_____
完成日期	2026 年 11 月 1 日

一、数据集基本信息

条目	说明
数据集名称	New York City TLC Yellow Taxi Trip Records（2024 年 1—12 月）
数据提供方	New York City Taxi and Limousine Commission（纽约市出租车与豪华轿车委员会，TLC）
数据页面	https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page
下载域	https://d37ci6vzurychx.cloudfront.net（TLC 官方 CloudFront 托管）
获取方式	Python urllib 通过 HTTPS 直接下载官方 Parquet / CSV / ZIP 文件，支持断点续传
获取日期	2026 年 10 月 30 日
许可与条款	纽约市政府公开发布的匿名行程数据；按 TLC 数据页说明与 NYC Open Data 使用条款使用，数据按原样提供、不作准确性担保
分析窗口	2024-01-01 至 2024-12-31（以乘客上车时间为准，时区为 America/New_York）
数据规模	12 个月度 Parquet，合计 41,169,720 行、693,001,713 字节（660.9 MiB）
辅助文件	taxi_zone_lookup.csv（265 个区域名称与行政区）、taxi_zones.zip（区域边界 Shapefile）

上述数据为 TLC 按月度公开发布的黄色出租车行程记录，字段包括上下车时间、乘客数、行程距离、费率代码、上下车区域编号、支付方式、车费、小费、路桥费、拥堵费与总金额。区域编号需与 taxi_zone_lookup.csv 关联后才能还原为地名，边界文件用于绘制分区地图。

二、获取方式与合规性

本项目数据全部来自纽约市 TLC 官方数据页所列的下载地址，属于课程允许的“官方网站文件下载”方式。下载前核对数据页的字段说明与使用条款，下载后逐个计算 SHA-256 并与审计记录比对，全过程由 scripts/01_load.py 完成，可重复执行。

（1）官方渠道。12 个月度文件均从 TLC 官方 CloudFront 域名的 /trip-data/ 路径下载，区域查询表与边界文件从 /misc/ 路径下载；未使用第三方镜像、网盘转存、论坛附件或来源不明的数据副本，也未使用 Kaggle 等二次分发页面。

（2）技术实现。脚本使用 Python 标准库 urllib 发起 HTTPS 请求，先以 HEAD 获取文件长度，再以 1 MiB 分块写入临时文件，支持 Range 断点续传；下载完成后用 pyarrow 读取 Parquet 元数据，记录行数、列名、字节数与 SHA-256，生成 outputs/tables/raw_audit.json。整个过程只访问上述官方文件地址，不解析网页、不执行页面脚本。

（3）未使用爬虫。本项目未使用 Scrapy、requests + HTML 解析、Playwright 等网页抓取技术，未模拟登录、未绕过验证码、robots 协议、访问频率限制或付费墙，也未对 TLC 网站发起高频请求。项目中的 Selenium 仅用于对本地运行的 Streamlit 大屏（localhost:8501）自动截图，供论文插图使用；它不访问外部网站，也不采集任何数据。

（4）数据性质。TLC 行程数据是纽约市政府主动公开的匿名运营记录，用于监管、研究与分析。数据页明确说明数据按原样提供，TLC 不对其准确性、完整性或及时性作担保；本文在使用中对明显异常值做了清洗，并在论文中披露清洗规则与保留率，不把原始数据直接当作“真值”。

三、许可与使用范围

本项目按 NYC Open Data 使用条款与 TLC 数据页说明使用数据：①仅用于嘉兴大学《商业数据分析》课程期末作业与相关课堂展示，不用于任何商业目的；②在论文、图表与仓库中标注数据来源为 NYC TLC；③不声称对原始数据拥有版权，也不对数据作超出其发布口径的再保证。

原始 Parquet、区域边界与查询表合计约 661 MiB，体积较大且属于政府原始发布物，因此不提交到公开仓库；仓库通过 .gitignore 排除 data/raw 与 data/clean，仅提交脚本、聚合表、图表与文档。120 万行分层样本与聚合中间表不随仓库分发，运行 python run_all.py --download 即可从上述官方地址重建全部原始数据、清洗结果、图表与大屏。

若课程要求、NYC Open Data 使用条款或 TLC 数据页说明之间存在冲突，以更严格者为准；如数据提供方提出异议，将立即停止使用并删除相关数据副本。

四、文件清单与完整性校验

下表列出 12 个月度文件的规模与 SHA-256。校验值由 scripts/01_load.py 在下载后计算，与 outputs/tables/raw_audit.json 中记录一致；重新下载后可用同一脚本复核。

文件	行数	MiB	SHA-256
yellow_tripdata_2024-01.parquet	2,964,624	47.6	c4d59da7bbc8abaeeeb1727947ee93d9891a71acb42854bd80db1571b2030510
yellow_tripdata_2024-02.parquet	3,007,526	48.0	c76c43c18c6c6664080dd920baab4928988d5786a6b65980792ca7cd796f9f20
yellow_tripdata_2024-03.parquet	3,582,628	57.3	2d4cdc8fb96726cdd3803b13b02d2e61e71d45720aff0ebc693a8bdd1f249823
yellow_tripdata_2024-04.parquet	3,514,289	56.4	ce37f736c7cf9e92164c850ef2b502a8f7bb590fc1804b6edbcb80293da01b89
yellow_tripdata_2024-05.parquet	3,723,833	59.7	1974230be2b5a3ea92e47b5eb77f32dbf1de896d81ad8df4ab6faba52749ad23
yellow_tripdata_2024-06.parquet	3,539,193	57.1	677cf14c8347f745b583f012fbdba072334c6c4efa17bfd6a64369f2ba30329c
yellow_tripdata_2024-07.parquet	3,076,903	49.9	af12d6b04daeb78550799ae99933d495b27d715b6dbb0fad9bb750a4537d3070
yellow_tripdata_2024-08.parquet	2,979,183	48.7	7315643dd16bafc03e27d9903edbfd35404c2550a695d0da0a3e73852d940cfb
yellow_tripdata_2024-09.parquet	3,633,030	58.3	2f42e4a383a6635de803001462848d0aee2b47f6ce899126805d2d05361fb843
yellow_tripdata_2024-10.parquet	3,833,771	61.4	d19fe05aa0b259af24eb47051735293287f1e6dc263ba04030ec1ab4c6ec2650
yellow_tripdata_2024-11.parquet	3,646,369	57.8	5ef321876de5007a7c147a347389133fc94fd7ac28f82eb1d57d8f2cf05cfd3b
yellow_tripdata_2024-12.parquet	3,668,371	58.7	41ebf7db80bebde60c58e5143c14cdf38ad04a0f3e3ff44215b3e240d55f6c78
taxi_zone_lookup.csv	—	0.01	1a99e105092230f8620f301edcca7f80d3080642ff404d28ed957d3fa222c8ed
taxi_zones.zip	—	0.98	f6d711917bb4340f8f644d5366c51665489eb2d426dd1a4a55677721ae5adf17

12 个行程文件合计 41,169,720 行；区域查询表 265 行（含未知区域与市外区域各 1 行），边界文件包含 263 个分区面。文件行数与 TLC 数据页的月度规模一致，未发现截断或重复下载。

五、数据内容与字段使用

本文使用的主要字段包括：tpep_pickup_datetime / tpep_dropoff_datetime（上下车时间）、passenger_count（乘客数）、trip_distance（里程）、RatecodeID（费率代码）、PULocationID / DOLocationID（上下车分区）、payment_type（支付方式）、fare_amount（车费）、tip_amount（小费）、tolls_amount（路桥费）、congestion_surcharge（拥堵费）、Airport_fee（机场费）与 total_amount（总金额）。

由上述字段派生出行程时长、平均速度、小时、星期、是否周末、是否高峰、时段、小费率、是否慷慨小费、是否机场相关行程、上车/下车行政区等分析变量。金额单位均为美元；小费率仅在信用卡支付且车费大于 0 时计算，现金支付的小费不可观测，相关结论不外推到现金行程。机场相关行程的定义为：费率代码属于 JFK（2）或 Newark（3），或上下车分区属于 1、132、138。

六、隐私与伦理

TLC 行程数据不含乘客姓名、电话、邮箱、身份证号、银行卡号或司机身份信息，也不含精确门牌地址；位置信息仅到出租车分区（zone）级别，时间为分钟级。数据由 TLC 在发布前做匿名化处理，本文未尝试与任何外部数据关联，也未进行个体识别或再识别。

本文的分析单位是行程、分区、小时与日期，所有结论以聚合口径呈现；涉及区域差异的表述仅用于运营建议，不对任何乘客、司机、社区或行政区作贬损性评价。论文中的地图只展示分区边界与聚合指标，不展示单笔行程的起讫点轨迹。

七、数据处理与留存

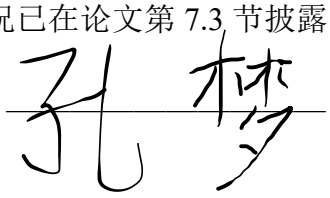
原始数据共 41,169,720 行。清洗规则为：①仅保留上车时间在 2024 年内的记录；②行程时长限定 1—240 分钟，里程限定 0.01—100 英里，车费与总金额非负；③上下车分区须在 TLC 1—263 号区域内；④乘客数缺失不删除，保留并在分析中按可用样本处理；⑤小费率仅对信用卡且车费大于 0 的行程计算。清洗后保留 39,192,643 行，保留率 95.20%。

被剔除的记录为：时长异常 524,922 行、里程异常 777,918 行、金额为负 733,884 行、分区异常 425,655 行、跨年记录 56 行（同一记录可能触发多条规则，故各项之和大于剔除总数）。按“上下车时间 + 上下车分区 + 总金额”识别的重复键共 9 行；TLC 数据不含行程唯一编号，无法做严格去重，该计数仅用于质量披露。乘客数、费率代码、拥堵费与机场费四个字段各有 4,091,232 行为空，本文未对其做插补，而是在相应分析中排除或单独标注。

为兼顾可视化与建模，本文另抽取 120 万行分层样本（每月 10 万行，随机种子为 42 加月份序号），仅用于分布图、散点图与小费模型；总量、收入、分区排名与预测均使用全量聚合表。原始数据与清洗后的明细仅保存在本地，不进入版本库、不公开分享；仓库只保留聚合表、图表与脚本。课程结束后可按教师要求删除本地原始数据副本。

八、声明

本人声明：上述数据获取、使用与共享行为真实、合规；数据来自 NYC TLC 官方发布地址，未使用网页爬虫或任何规避访问控制的手段；已阅读并遵守 TLC 数据页说明与 NYC Open Data 使用条款；论文中的分析结果由本人基于上述数据完成，所有数值均与 outputs/tables 下的结果表核对。通用 AI 编程助手仅用于查询个别 API 用法、排查运行错误与语句润色，不参与数据获取、清洗口径、模型设定与结论形成；AI 使用情况已在论文第 7.3 节披露。

作者签名：  　　日期：2026 年 11 月 1 日